

Diffusion Models 学习笔记

DDPM & DDIM ——公式推导与个人理解

2026 年 5 月 29 日

目录

1	Introduction to Diffusion Models	2
2	DDPM: Denoising Diffusion Probabilistic Models	2
2.1	Forward Process (前向扩散过程)	2
2.2	Reverse Process (逆向去噪过程)	3
2.3	Parameterization (参数化方式)	3
2.4	Sampling (采样算法)	3
3	DDIM: Denoising Diffusion Implicit Models	4
3.1	Motivation	4
3.2	Non-Markovian Forward Process	4
3.3	Deterministic Sampling (确定性采样)	5
3.4	General Sampling with η (带随机性的采样)	5
3.5	Accelerated Sampling (加速采样)	5
4	Connections & Comparisons	6
4.1	DDPM $\subset$ DDIM (DDPM 只是 DDIM 的特例)	6
4.2	实际使用建议 (Practical Considerations)	6
5	Summary of Key Formulas	7

1 Introduction to Diffusion Models

Diffusion models 是一类基于 Markov 链的生成模型。简单来说就是两个过程来回搞：

- **Forward process (扩散过程 / 加噪)**: 往数据 x_0 里逐步加 Gaussian 噪声，加 T 步之后变成纯噪声 $x_T \sim \mathcal{N}(0, I)$ 。
- **Reverse process (逆扩散过程 / 去噪)**: 从纯噪声 x_T 开始，一步步把噪声去掉，最后还原出像样的样本 x_0 。

DDPM 和 DDIM 都是在这个框架上做的，但思路不太一样，先放个对比表有个直观印象：

	DDPM	DDIM
前向过程	Markov 链	Markov 链 (复用 DDPM 的边际分布)
逆向过程	Markov 链 (随机)	非 Markov 链 (确定性)
采样速度	慢 ($T \approx 1000$)	快 (最低 10 ~ 50 步就能跑)
采样方式	随机采样	确定性 / 半随机 (η 控制)

个人理解：DDIM 最妙的地方在于——它不重新训练模型，直接拿 DDPM 训练好的权重就能用，只是换了一种采样思路，速度直接快了几十倍。后面会详细讲为什么可以这样。

2 DDPM: Denoising Diffusion Probabilistic Models

2.1 Forward Process (前向扩散过程)

前向过程是一个固定的 Markov 链，一步步往数据里加高斯噪声，没什么可学的参数：

$$q(x_{1:T} | x_0) = \prod_{t=1}^T q(x_t | x_{t-1}) \quad (1)$$

每一步的条件分布是个 Gaussian：

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I) \quad (2)$$

其中 $\beta_t \in (0, 1)$ 是 noise schedule，控制每一步加多少噪声。实际操作中 $\beta_1 \approx 10^{-4}$ 线性增加到 $\beta_T \approx 0.02$ （这个值是 DDPM 论文里的经典设置，后面也有工作改进过这个 schedule，但这里不展开）。

重参数化技巧 (Reparameterization Trick). 这是扩散模型里最常用的技巧之一。定义 $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。因为高斯分布的可加性很好，我们可以跳过中间步骤，直接从 x_0 算出任意时间步的 x_t ：

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I) \quad (3)$$

也就是：

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (4)$$

注意：这个公式超级重要，后面训练和采样都会反复用到。本质就是把 x_t 写成了 x_0 和噪声 ϵ 的线性组合。

当 $T \rightarrow \infty$ 时 $\bar{\alpha}_t \rightarrow 0$ ，所以 $q(x_T | x_0) \approx \mathcal{N}(0, I)$ ——也就是说加到最后基本就是纯噪声了，这也符合直觉。

2.2 Reverse Process (逆向去噪过程)

逆向过程是我们真正要学的部分。同样建模成 Markov 链，从 $p(x_T) = \mathcal{N}(0, I)$ 开始一步步去噪：

$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^T p_\theta(x_{t-1} | x_t) \quad (5)$$

每一步假设为 Gaussian（这个假设在 β_t 足够小时是合理的）：

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)) \quad (6)$$

这里 μ_θ 和 Σ_θ 都是神经网络要学的东西，不过实际 DDPM 把方差固定了，只学均值 μ_θ 。

2.3 Parameterization (参数化方式)

顺着上面的思路，把 μ_θ 参数化成和 $\tilde{\mu}_t$ 一样的形式：

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \epsilon_\theta(x_t, t) \right) \quad (7)$$

ϵ_θ 是一个神经网络（结构上通常是 U-Net），输入是 noisy 的 x_t 和时间步 t ，输出是对噪声 ϵ 的预测。

这样 L_{t-1} 就化简成一个非常干净的形式——MSE 噪声预测误差：

$$L_{\text{simple}} = \mathbb{E}_{t, x_0, \epsilon} \left[\|\epsilon - \epsilon_\theta(x_t, t)\|^2 \right] \quad (8)$$

其中 $t \sim \mathcal{U}\{1, \dots, T\}$, $x_0 \sim q(x_0)$, $\epsilon \sim \mathcal{N}(0, I)$, $x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon$ 。

这就是 DDPM 最终用的 loss，极其简洁。训练时不需要变分推断那套复杂的 ELBO 计算——随机采一个 t ，采一张图，加噪声，让网络预测噪声，算 MSE，反向传播。没了。

2.4 Sampling (采样算法)

训练完之后，推理时从 $x_T \sim \mathcal{N}(0, I)$ 开始，对 $t = T, T-1, \dots, 1$ 一步步迭代去噪：

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z \quad (9)$$

$z \sim \mathcal{N}(0, I)$ ($t > 1$ 时加噪声，最后一步 $t = 1$ 时 $z = 0$ 不加)。方差 σ_t^2 一般取 β_t 或者 $\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$ (后者是 posterior variance，理论上更合理一点)。

直观理解采样公式：第一项 $\frac{1}{\sqrt{\alpha_t}} (x_t - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \epsilon_\theta)$ 是预测的去噪均值 μ_θ ，第二项 $\sigma_t z$ 是额外注入的随机噪声——相当于每步去一点噪再加一点噪声，防止过程塌掉。随着 t 减小， σ_t 也越来越小，随机性逐渐减弱。

Algorithm 1 DDPM Training

```

1: while not converged do
2:    $x_0 \sim q(x_0)$ 
3:    $t \sim \mathcal{U}(\{1, \dots, T\})$ 
4:    $\epsilon \sim \mathcal{N}(0, I)$ 
5:   Take gradient descent step on  $\nabla_{\theta} \|\epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)\|^2$ 
6: end while

```

Algorithm 2 DDPM Sampling

```

1:  $x_T \sim \mathcal{N}(0, I)$ 
2: for  $t = T, \dots, 1$  do
3:    $z \sim \mathcal{N}(0, I)$  if  $t > 1$ , else  $z = 0$ 
4:    $x_{t-1} = \frac{1}{\sqrt{\alpha_t}} (x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(x_t, t)) + \sigma_t z$ 
5: end for
6: return  $x_0$ 

```

3 DDIM: Denoising Diffusion Implicit Models

3.1 Motivation

DDPM 有几个很明显的痛点:

- 采样要跑满 T 步 (通常 $T = 1000$), 生成一张图慢得离谱。
- 采样是随机的——同一个 x_T 跑两次结果不一样, 没法复现。
- 如果强行减少步数 (比如只跑 100 步), 生成质量会大幅下降, 因为训练和推理的步数不匹配。

DDIM 的想法很聪明: 前向过程的边际分布 $q(x_t | x_0)$ 保持和 DDPM 一模一样, 但不要求逆向过程必须是 Markov 的。这样一来, 已经训练好的 DDPM 模型不用动, 只需要换一种采样方式, 就能用更少步数、甚至确定性地生成。本质上是在”白嫖” DDPM 的训练成果。

3.2 Non-Markovian Forward Process

DDIM 定义一个非 Markov 的前向过程, 其联合分布为:

$$q_{\sigma}(x_{1:T} | x_0) = q_{\sigma}(x_T | x_0) \prod_{t=2}^T q_{\sigma}(x_{t-1} | x_t, x_0) \quad (10)$$

其中每一步的条件分布为:

$$q_{\sigma}(x_{t-1} | x_t, x_0) = \mathcal{N}(x_{t-1}; \sqrt{\bar{\alpha}_{t-1}} x_0 + \sqrt{1 - \bar{\alpha}_{t-1} - \sigma_t^2} \cdot \frac{x_t - \sqrt{\bar{\alpha}_t} x_0}{\sqrt{1 - \bar{\alpha}_t}}, \sigma_t^2 I) \quad (11)$$

可以验证, 这个非 Markov 的前向过程仍然保持和 DDPM 一样的边际分布:

$$q_\sigma(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I) \quad (12)$$

这就是 DDIM 的核心 trick: 边际分布不变 $\Rightarrow$ 训练目标不变 $\Rightarrow$ 已经训练好的 DDPM 模型可以直接拿来用，一行代码都不用改。换采样算法就行。

3.3 Deterministic Sampling (确定性采样)

当 $\sigma_t = 0$ 时，逆向过程变为确定性映射。给定 x_t ，可以用 ϵ_θ 预测 x_0 ：

$$\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}} \quad (13)$$

然后沿着「指向 x_t 」的方向得到 x_{t-1} ：

$$x_{t-1} = \underbrace{\sqrt{\bar{\alpha}_{t-1}} \hat{x}_0}_{\text{predicted } x_0 \text{ component}} + \underbrace{\sqrt{1 - \bar{\alpha}_{t-1}} \epsilon_\theta(x_t, t)}_{\text{denoised direction to } x_t} \quad (14)$$

这实际上就是在用 Euler 法求解某个 ODE，所以 DDIM 可以理解为把扩散模型的采样变成了一个 ODE 求解问题——这也是后来 consistency models、rectified flow 等一系列加速采样工作的思想源头。

3.4 General Sampling with η (带随机性的采样)

引入超参数 $\eta \in [0, 1]$ 控制采样的随机性：

$$\sigma_t = \eta \cdot \sqrt{\frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}} \cdot \sqrt{1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}} \quad (15)$$

- $\eta = 0$: 确定性 DDIM (等价于 probability flow ODE)。
- $\eta = 1$: 恢复 DDPM 的随机采样 (当 σ_t 取 DDPM 形式时)。
- $0 < \eta < 1$: 介于两者之间。

通用采样公式为：

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1} - \sigma_t^2} \epsilon_\theta(x_t, t) + \sigma_t \epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (16)$$

3.5 Accelerated Sampling (加速采样)

由于 $q_\sigma(x_t | x_0)$ 不依赖具体的采样路径，DDIM 可以在一个子序列上进行采样。

令 τ 为 $\{1, \dots, T\}$ 的长度为 S ($S \ll T$) 的子序列，则 $x_{\tau_{s-1}}$ 可以直接由 x_{τ_s} 得到：

$$x_{\tau_{s-1}} = \sqrt{\bar{\alpha}_{\tau_{s-1}}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{\tau_{s-1}} - \sigma_{\tau_s}^2} \epsilon_\theta(x_{\tau_s}, \tau_s) + \sigma_{\tau_s} \epsilon \quad (17)$$

实际用的时候 S 取 10 到 50 步就能出质量不错的结果，和 DDPM 全 1000 步比几乎看不出来区别，快了 20-100 倍。这个加速比在当时的硬件条件下简直是降维打击。

Algorithm 3 DDIM Sampling (deterministic, $\eta = 0$)

```
1:  $x_T \sim \mathcal{N}(0, I)$ 
2: for  $t = T, T - \Delta t, \dots, 1$  do ▷ 使用子序列，步长  $\Delta t$ 
3:    $\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}$ 
4:    $x_{t-\Delta t} = \sqrt{\bar{\alpha}_{t-\Delta t}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{t-\Delta t}} \epsilon_\theta(x_t, t)$ 
5: end for
6: return  $x_0$ 
```

4 Connections & Comparisons

4.1 DDPM $\subset$ DDIM (DDPM 只是 DDIM 的特例)

DDPM 其实是 DDIM 框架的一个 corner case。当 $\eta = 1$ 而且跑满 T 步时，DDIM 的采样就和 DDPM 的随机采样完全一样了。

验证一下，取 σ_t 如式 (15)，令 $\eta = 1$ ：

$$\sigma_t = \sqrt{\frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}} \cdot \sqrt{1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}} = \sqrt{\frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}} \beta_t = \sqrt{\tilde{\beta}_t} \quad (18)$$

$\tilde{\beta}_t$ 就是 DDPM 里 posterior variance 的那个下界。对上了。

所以可以理解为：DDIM 是 DDPM 采样过程的”超集”——DDPM 只是 DDIM 在 $\eta = 1$ 、全步长下的特例。

4.2 实际使用建议 (Practical Considerations)

- **训练**：DDPM 和 DDIM 训练完全一样，没有任何区别。用 DDPM 训好的 checkpoint 直接就能拿来做法 DDIM 推理，不需要重新训练。
- **采样质量 vs 速度的取舍**：
 - DDPM ($T = 1000$)：质量上限最高，但真的慢。
 - DDIM ($S = 10 \sim 50, \eta = 0$)：质量差不太多，但快 20 ~ 100 倍，日常用最划算。
 - DDIM ($S = 10 \sim 50, \eta > 0$)：加一点随机性，质量在某些场景（尤其高分辨率）会比纯确定性略好，同时还是比 DDPM 快很多。
- **确定性的好处**： $\eta = 0$ 时 x_T 唯一确定 x_0 ，DDIM 就变成了一个隐式模型（给定噪声 $\rightarrow$ 给定图片），可以做 latent space interpolation、语义编辑之类好玩的操作。这点 DDPM 做不到，因为它的随机性导致同样的 x_T 每次跑出来的结果不同。

5 Summary of Key Formulas

Notation

Symbol	Meaning
x_0	clean data sample
x_t	noisy sample at timestep t
β_t	noise variance scheduled at step t
α_t	$1 - \beta_t$
$\bar{\alpha}_t$	$\prod_{s=1}^t \alpha_s$
ϵ	standard Gaussian noise $\mathcal{N}(0, I)$
ϵ_θ	noise prediction network (U-Net)
T	total diffusion steps (e.g., 1000)

DDPM Cheat Sheet

$$\text{Forward:} \quad q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I) \quad (19)$$

$$\text{Marginal:} \quad q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I) \quad (20)$$

$$\text{Noisy sample:} \quad x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon \quad (21)$$

$$\text{Loss function:} \quad L_{\text{simple}} = \mathbb{E}_{t, x_0, \epsilon} \|\epsilon - \epsilon_\theta(x_t, t)\|^2 \quad (22)$$

$$\text{Sampling:} \quad x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z \quad (23)$$

DDIM Cheat Sheet

$$\text{Predicted } x_0 : \quad \hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}} \quad (24)$$

$$\text{Sampling (general):} \quad x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1} - \sigma_t^2} \epsilon_\theta(x_t, t) + \sigma_t \epsilon \quad (25)$$

$$\text{Deterministic}(\eta = 0) : \quad x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1}} \epsilon_\theta(x_t, t) \quad (26)$$

$$\text{Noise scale:} \quad \sigma_t = \eta \cdot \sqrt{\frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}} \cdot \sqrt{1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}} \quad (27)$$

Relationships (总结三者关系)

- $\eta = 1$ + 全步长 $\Rightarrow$ 回到 DDPM 随机采样。
- $\eta = 0$ + 子序列 $\Rightarrow$ 确定性 DDIM，快速采样。
- Score connection: $\epsilon_\theta(x_t, t) \approx -\sqrt{1 - \bar{\alpha}_t} \nabla_{x_t} \log p_t(x_t)$ ，连接了扩散模型和 score-based 模型。

写到最后：DDPM 和 DDIM 的核心区别其实就一句话——DDPM 用 Markov 链做随机采样，DDIM 换了个非 Markov 的视角把它变成了类 ODE 的确定性过程。DDIM 没有重新定义训练，只是换了采样方式，所以是”免费”的加速。理解了这一点，后面看 consistency models、rectified flow、flow matching 这些后续工作就容易多了。本质上大家都在想办法让这个”噪声 → 数据”的映射更快、更稳、更可控。

参考文献

- [1] J. Ho, A. Jain, and P. Abbeel, *Denoising Diffusion Probabilistic Models*, NeurIPS, 2020.
- [2] J. Song, C. Meng, and S. Ermon, *Denoising Diffusion Implicit Models*, ICLR, 2021.
- [3] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole, *Score-Based Generative Modeling through Stochastic Differential Equations*, ICLR, 2021.
- [4] A. Nichol and P. Dhariwal, *Improved Denoising Diffusion Probabilistic Models*, ICML, 2021.